



Actividades Práctico-Experimentales

Nro. 011

1. Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	2
Resultado de aprendizaje de la unidad	Evalúa el comportamiento probabilístico de variables aleatorias continuas mediante el ajuste a la distribución Normal y el cálculo de áreas bajo la curva, aplicando estandarización (puntajes Z) para la toma de decisiones basada en datos empíricos.
Práctica Nro.	011
Título de la Práctica	Inferencia Estadística Multigrupo: Análisis de Varianza (ANOVA de 1 factor) y Pruebas Post-Hoc (Tukey)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Grupo A	Isaac Vire Carlos Martinez Erick Rogel Mateo Yanangomez Elvis Guayllas
Fecha	Martes 29 de junio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

2. Objetivo(s) de la Práctica:

- **Modelar** el contraste de hipótesis para más de dos medias poblacionales mediante el estadístico de Fisher-Snedecor (ANOVA de un factor) utilizando scipy.stats.
- **Aplicar** el diseño de un experimento comparativo multigrupo sobre variables categóricas del Proyecto Integrador, optimizando la toma de decisiones basada en datos (ABP).
- **Ejecutar** pruebas de comparaciones múltiples (Post-hoc), específicamente Tukey HSD, para identificar qué pares de grupos presentan diferencias significativas sin inflar el error tipo I (ABI).

3. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

4. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

5. Procedimiento / Metodología

1. Metodología (Enfoque PID-2025):

- **ABP:** Comparar múltiples grupos (ej. 3+ cantones, 3+ proveedores) mediante ANOVA, evitando el error de realizar múltiples pruebas T independientes.
- **ABI:** Investigación sobre el Family-Wise Error Rate (FWER) y cómo las pruebas Post-hoc controlan la tasa de falsos positivos en comparaciones múltiples.

Tarea 1: Análisis de Varianza (ANOVA de 1 factor)

El ANOVA compara la varianza entre los grupos frente a la varianza dentro de los grupos.

- H0: Todas las medias poblacionales son iguales.
- H1: Al menos una media poblacional es diferente.

Ejemplo:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import f_oneway
```

Ejemplo: Tiempos de respuesta (ping) de 3 algoritmos

```
np.random.seed(42)
grupo_A = np.random.normal(loc=45.0, scale=5.0, size=30)
grupo_B = np.random.normal(loc=46.5, scale=4.8, size=30)
grupo_C = np.random.normal(loc=52.0, scale=5.5, size=30)
```

```
stat_f, p_val_f = f_oneway(grupo_A, grupo_B, grupo_C)
print(f"Estadístico F: {stat_f:.4f} | Valor-p: {p_val_f:.4e}")
```

Tarea 2: Hito del Proyecto - Segmentación Multigrupo

1. Importe su dataset regional.
2. Identifique una variable categórica con al menos 3 niveles (ej. tipo de conexión, meses, sectores).
3. Ejecute `f_oneway` y redacte un dictamen técnico: ¿El ANOVA sugiere que existen diferencias significativas entre los niveles? ¿Es necesario investigar más a fondo?

Tarea 3: Pruebas Post-hoc (Tukey HSD)

Si el ANOVA rechaza H_0 , debemos identificar qué pares difieren.

```
from statsmodels.stats.multicomp import pairwise_tukeyhsd
```

Preparación de datos

```
datos_combinados = pd.DataFrame({'Valor': np.concatenate([grupo_A, grupo_B, grupo_C]),  
                                'Grupo': ['A']*30 + ['B']*30 + ['C']*30})
```

```
tukey = pairwise_tukeyhsd(endog=datos_combinados['Valor'],  
                          groups=datos_combinados['Grupo'],  
                          alpha=0.05)
```

```
print(tukey)
```

```
tukey.plot_simultaneous()
```

```
plt.show()
```

6. Resultados del Grupo A:

- Resultados de la Tarea 1

```
import numpy as np  
import pandas as pd  
import seaborn as sns  
import matplotlib.pyplot as plt  
from scipy.stats import f_oneway  
  
# Ejemplo: Tiempos de respuesta (ping) de 3 algoritmos  
  
np.random.seed(42)  
  
grupo_A = np.random.normal(loc=45.0, scale=5.0, size=30)  
grupo_B = np.random.normal(loc=46.5, scale=4.8, size=30)  
grupo_C = np.random.normal(loc=52.0, scale=5.5, size=30)  
stat_f, p_val_f = f_oneway(grupo_A, grupo_B, grupo_C)  
  
print(f"Estadístico F: {stat_f:.4f} | Valor-p: {p_val_f:.4e}")  
  
Estadístico F: 22.6087 | Valor-p: 1.2389e-08
```

- Resultados de la Tarea 2



```

import pandas as pd
from scipy import stats

nombres_columnas = ["Fecha", "Tipo", "Emisor", "Cantidad", "Valor_Nominal",
                    "Precio", "Valor_Nominal_Total", "Monto_Efectivo",
                    "Casa_Origen", "Casa_Destino", "Bolsa"]

df = pd.read_csv("BVG_Acciones_export.csv", names=nombres_columnas, skiprows=1)

df['Precio'] = pd.to_numeric(df['Precio'], errors='coerce')
df = df.dropna(subset=['Precio', 'Emisor'])

def categorizar_sector(emisor):
    emisor = emisor.upper()
    if "BANCO" in emisor:
        return "Bancario"
    elif any(keyword in emisor for keyword in ["INDUSTRIAL", "CERVECERIA", "HOLCIM", "SURPAPEL"]):
        return "Industrial"
    elif "FAVORITA" in emisor:
        return "Comercial"
    else:
        return "Otros"

df['Sector'] = df['Emisor'].apply(categorizar_sector)

# Segmentación de Grupos
grupo_bancos = df[df['Sector'] == 'Bancario']['Precio']
grupo_industrial = df[df['Sector'] == 'Industrial']['Precio']
grupo_comercial = df[df['Sector'] == 'Comercial']['Precio']

# Ejecución del ANOVA (f_oneway)
f_stat, p_value = stats.f_oneway(grupo_bancos, grupo_industrial, grupo_comercial)

alpha = 0.05

print("--- RESULTADOS DEL ANÁLISIS ANOVA ---")
print(f"Sectores Analizados: Bancario (n={len(grupo_bancos)}), Industrial (n={len(grupo_industrial)}), Comercial (n={len(grupo_comercial)})")
print(f"Estadístico F: {f_stat:.4f}")
print(f"Valor P (p-value): {p_value:.4f}")
print("-" * 38)

if p_value <= alpha:
    print("DICTAMEN: SE RECHAZA LA HIPÓTESIS NULA (Ho).")
    print("CONCLUSIÓN (H1): Existen diferencias significativas entre los precios promedio de los sectores.")
else:
    print("DICTAMEN: NO SE RECHAZA LA HIPÓTESIS NULA (Ho).")
    print("CONCLUSIÓN: No existe evidencia suficiente para afirmar que los promedios de precios son distintos.")

```

```

--- RESULTADOS DEL ANÁLISIS ANOVA ---
Sectores Analizados: Bancario (n=7108), Industrial (n=2079), Comercial (n=14881)
Estadístico F: 4786.1322
Valor P (p-value): 0.0000
-----
DICTAMEN: SE RECHAZA LA HIPÓTESIS NULA (Ho).
CONCLUSIÓN (H1): Existen diferencias significativas entre los precios promedio de los sectores.

```

¿El ANOVA sugiere que existen diferencias significativas entre los niveles? ¿Es necesario investigar más a fondo?

El resultado del ANOVA rechaza H_0 y nos dice que hay diferencias significativas entre las medias de los grupos comparados. En otras palabras, existen diferencias significativas entre los precios promedio de los sectores. Por lo cual se tendría que, ante la evidencia, ejecutar una investigación más a fondo para saber qué sectores muestran diferencias entre sí, podemos hacer esto con la ayuda de Post-Hoc de Tukey. También podríamos de paso saber si las varianzas de los grupos son iguales, con el test de Levene, y entonces llevar a cabo el uso de otras herramientas estadísticas.

- Resultados de la Tarea 3

```

from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt
import numpy as np


datos_combinados = pd.DataFrame({'Valor': np.concatenate([grupo_bancos.values, grupo_industrial.values, grupo_comercial.values]),
                                'Grupo': ([('Bancario') * len(grupo_bancos)] + [('Industrial') * len(grupo_industrial)] + [('Comercial') * len(grupo_comercial)])})

tukey = pairwise_tukeyhsd(endog=datos_combinados['Valor'], groups=datos_combinados['Grupo'], alpha=0.05)

print("\n--- RESULTADOS PRUEBA POST-HOC (TUKEY) ---")
print(tukey)

tukey.plot_simultaneous()
plt.show()

```



Prueba de Kruskal-Wallis

```
import pandas as pd
from scipy import stats

nombres_columnas = ["Fecha", "Tipo", "Emisor", "Cantidad", "Valor_Nominal",
                    "Precio", "Valor_Nominal_Total", "Monto_Efectivo",
                    "Casa_Origen", "Casa_Destino", "Bolso"]

df = pd.read_csv("BVG_Acciones_export.csv", names=nombres_columnas, skiprows=1)
df['Precio'] = pd.to_numeric(df['Precio'], errors='coerce')
df = df.dropna(subset=['Precio', 'Emisor'])

def categorizar_sector(emisor):
    emisor = emisor.upper()
    if "BANCO" in emisor: return "Bancario"
    elif any(kw in emisor for kw in ["INDUSTRIAL", "CERVECERIA", "HOLCIM", "SURPAPEL"]): return "Industrial"
    elif "FAVORITA" in emisor: return "Comercial"
    else: return "Otros"

df['Sector'] = df['Emisor'].apply(categorizar_sector)

grupo_bancos = df[df['Sector'] == 'Bancario']['Precio']
grupo_industrial = df[df['Sector'] == 'Industrial']['Precio']
grupo_comercial = df[df['Sector'] == 'Comercial']['Precio']
```

```
# Ejecución de la prueba de Kruskal-Wallis
h_stat, p_value = stats.kruskal(grupo_bancos, grupo_industrial, grupo_comercial)

alpha = 0.05

print("--- RESULTADOS DE LA PRUEBA DE KRUSKAL-WALLIS ---")
print(f"Estadístico H: {h_stat:.4f}")
print(f"Valor P (p-value): {p_value:.4f}")
print("-" * 50)

if p_value <= alpha:
    print("DICTAMEN: SE RECHAZA LA HIPÓTESIS NULA (Ho).")
    print("CONCLUSIÓN (H1): Existen diferencias significativas entre las medianas de los sectores.")
else:
    print("DICTAMEN: NO SE RECHAZA LA HIPÓTESIS NULA (Ho).")
    print("CONCLUSIÓN: No hay evidencia suficiente para afirmar que las medianas son distintas.")

--- RESULTADOS DE LA PRUEBA DE KRUSKAL-WALLIS ---
Estadístico H: 6656.3850
Valor P (p-value): 0.0000
-----
DICTAMEN: SE RECHAZA LA HIPÓTESIS NULA (Ho).
CONCLUSIÓN (H1): Existen diferencias significativas entre las medianas de los sectores.
```

- Enlace al Google Colab:

<https://colab.research.google.com/drive/1Y4cCmuGIhHaHowPYVxka-It3dwjigaER?usp=sharing>

7. Preguntas de Control:

- Utilice `scipy.stats.levene` para verificar la igualdad de varianzas.

```
# Verificación de Igualdad de Varianzas con Test de Levene
# Ho: Las varianzas son iguales
# H1: Al menos una varianza es distinta
stat_levene, p_levene = stats.levene(grupo_bancos, grupo_industrial, grupo_comercial)

alpha = 0.05

print("--- RESULTADOS DEL TEST DE LEVENE ---")
print(f"Estadístico W: {stat_levene:.4f}")
print(f"Valor P (p-value): {p_levene:.4f}")
print("-" * 38)

--- RESULTADOS DEL TEST DE LEVENE ---
Estadístico W: 1737.2797
Valor P (p-value): 0.0000
-----
```

- **Discusión:** Si el supuesto de homocedasticidad se viola, ¿qué alternativa no paramétrica (ej. Kruskal-Wallis) sería adecuada?

El valor p de la prueba de Levene es menor a la significancia establecida, por lo que rechazamos la hipótesis nula de igualdad de varianzas. Esto significa que las varianzas de los precios entre los sectores (Bancario, Industrial, Comercial) son significativamente diferentes.

Dado que el supuesto de homocedasticidad se viola, una alternativa adecuada es la prueba de Kruskal-Wallis. Esta está preparada para comparar tres o más grupos independientes sin asumir normalidad en la distribución de los datos ni una igualdad de varianzas, permitiéndonos obtener información de una manera más segura.

8. Conclusiones.

Dados los resultados obtenidos, el uso del ANOVA de un factor, la prueba Post-Hoc de Tukey y la implementación de la prueba de Levene resultan fundamentales. Estas herramientas permiten al estudiante o profesional comprender mejor la naturaleza de su conjunto de datos, las técnicas estadísticas aplicables y la fiabilidad de los resultados. En este análisis específico, respecto al dataset del grupo, hemos podido conocer cómo el mercado y sus precios se comportan en distintos sectores, y hemos identificado las herramientas estadísticas adecuadas para cada situación, considerando la naturaleza particular del dataset.

9. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio	Excelente (Pt)	Bueno (Pt)	Regular (Pt)	Insuficiente (Pt)
Procedimiento Técnico (4 pts)	Implementación correcta y completa de ANOVA, Tukey y validación de supuestos.	Implementación funcional con errores menores en el código o procesos.	Errores significativos en la ejecución del código estadístico.	No presenta el código o el mismo no es funcional.
Análisis Interpretación (3 pts)	Interpretación precisa de valores-p, supuestos y contrastes estadísticos.	Interpretación aceptable con detalles menores a mejorar.	Interpretación ambigua, incompleta o con errores conceptuales.	Sin interpretación o conclusiones fundamentadas.
Argumentación Técnica (3 pts)	Argumentación sólida, clara y vinculada directamente al contexto del proyecto.	Argumentación presente pero con falta de profundidad técnica.	Argumentación débil, superficial o poco fundamentada.	Sin argumentación técnica o dictamen.

10. Bibliografía

- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.
- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.
- [3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



11. Anexos

Enlace al Google Colab:

<https://colab.research.google.com/drive/1Y4cCmuGIhHaHowPYVxka-It3dwjigaER?usp=sharing>

12. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	