

Actividades Práctico-Experimentales

Nro. 012

Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	3
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	012
Título de la Práctica	Análisis Bivariado y Predicción: Correlación de Pearson y Modelo de Regresión Lineal Simple (OLS)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Grupo A	Isaac Vire Carlos Martinez Erick Rogel Mateo Yanangomez Elvis Guayllas
Fecha	Martes 06 de julio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

- **Construir** un modelo de Regresión Lineal Simple basado en el método de Mínimos Cuadrados Ordinarios (OLS) aplicado a dos variables críticas del dataset regional del Proyecto Integrador (ABP).
- **Investigar** y validar estadísticamente los supuestos subyacentes del modelo de regresión lineal (normalidad y homocedasticidad de los residuos) para garantizar la confiabilidad geométrica de la recta ajustada (ABI).
- **Cuantificar** la fuerza y dirección de la relación lineal entre dos variables continuas mediante el cálculo del Coeficiente de Correlación de Pearson (r) utilizando scipy.stats.

2. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

3. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante evolucionará de describir el pasado (estadística descriptiva) a predecir el futuro. Deberá encontrar qué variable de su región explica matemáticamente el comportamiento de otra, y utilizar esta relación para pronosticar escenarios no observados.
- **ABI (Aprendizaje Basado en Investigación):** Indagación crítica sobre por qué "Correlación no implica Causalidad" y la comprobación matemática rigurosa de los errores (residuos). Un modelo con buen R^2 puede ser engañoso si los residuos no son aleatorios.
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual, con interpretación predictiva orientada al Hito del Proyecto en grupos.

Tarea 1: Análisis de Correlación de Pearson

El coeficiente de correlación de Pearson (r) mide la dependencia lineal entre dos variables, oscilando entre -1 (correlación negativa perfecta) y 1 (correlación positiva perfecta).

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Abra un nuevo Jupyter Notebook llamado APE_013_Regresion.ipynb.

Escenario: Analizaremos la relación entre los "Usuarios Concurrentes" en un servidor (X) y el "Consumo de Ancho de Banda en Mbps" (Y).

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from scipy.stats import pearsonr

# Generación de datos simulados (Relación positiva fuerte con ruido)
np.random.seed(42)
usuarios_X = np.random.randint(50, 500, size=100)
# Y = 2.5*X + 50 + Ruido Aleatorio
ancho_banda_Y = 2.5 * usuarios_X + 50 + np.random.normal(0, 100, size=100)

# 1. Cálculo del Coeficiente de Pearson y su valor-p
coef_pearson, p_valor = pearsonr(usuarios_X, ancho_banda_Y)

print("--- Análisis de Correlación de Pearson ---")
print(f"Coeficiente (r): {coef_pearson:.4f}")
print(f"Valor-p (Significancia): {p_valor:.4e}")

if p_valor < 0.05:
    print("Conclusión: Existe una correlación lineal estadísticamente significativa.")
else:
    print("Conclusión: NO existe evidencia de correlación lineal significativa.")

# 2. Visualización: Diagrama de Dispersión (Scatter Plot)
plt.figure(figsize=(8, 5))
sns.scatterplot(x=usuarios_X, y=ancho_banda_Y, color='blue', alpha=0.7)
plt.title(f'Dispersión: Usuarios vs Ancho de Banda (r = {coef_pearson:.2f})')
plt.xlabel('Usuarios Concurrentes (X)')
plt.ylabel('Ancho de Banda Mbps (Y)')
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```

Tarea 2: Ajuste del Modelo de Regresión Lineal Simple (OLS)

Si existe correlación, podemos modelar la relación mediante una línea recta: $\hat{y} = \beta_0 + \beta_1 x$,

donde β_0 es el intercepto y β_1 la pendiente.

1. Utilizaremos statsmodels, ya que provee un resumen estadístico profundo al estilo de la econometría clásica.
2. Agregue y ejecute el siguiente código en su cuaderno:

```
import statsmodels.api as sm
```

```
# Para usar statsmodels, debemos añadir explícitamente la constante (intercepto beta_0) al  
predictor X
```

```
X_sm = sm.add_constant(usuarios_X)
```

```
Y_sm = ancho_banda_Y
```

```
# Ajuste del modelo por Mínimos Cuadrados Ordinarios (OLS)
```

```
modelo_ols = sm.OLS(Y_sm, X_sm).fit()
```

```
# Impresión del resumen estadístico
```

```
print(modelo_ols.summary())
```

```
# Extracción de parámetros para graficar la recta
```

```
beta_0 = modelo_ols.params[0]
```

```
beta_1 = modelo_ols.params[1]
```

```
plt.figure(figsize=(8, 5))
```

```
sns.scatterplot(x=usuarios_X, y=ancho_banda_Y, label='Datos Observados', color='gray')
```

```
# Dibujo de la recta de regresión
```

```
plt.plot(usuarios_X, beta_0 + beta_1 * usuarios_X, color='red', linewidth=2, label=f'Recta: Y =  
{beta_0:.2f} + {beta_1:.2f}X')
```

```
plt.title('Modelo de Regresión Lineal Simple')
```

```
plt.xlabel('Usuarios Concurrentes (X)')
```

```
plt.ylabel('Ancho de Banda Mbps (Y)')
```

```
plt.legend()
```

```
plt.show()
```


Tarea 3: Hito del Proyecto - Predicción en el Dataset Regional (ABP)

1. Importe su dataset regional mediante pandas.


2. Identifique una variable independiente/predictora (X) y una variable dependiente/respuesta (Y). Ejemplo: $X = \text{Precipitación}$, $Y = \text{Producción Agrícola}$.
3. Aplique el flujo de las Tareas 1 y 2: Calcule r , ajuste el modelo OLS e imprima el `summary()`.
4. **Predicción:** Usando los coeficientes obtenidos (β_0, β_1), calcule manualmente mediante código Python el valor esperado de Y para un valor crítico de X que **no** exista en su dataset original (pronóstico).
5. Interprete desde la perspectiva del negocio el valor del **R-squared** (R^2) que le arrojó el resumen estadístico.

5. Resultados obtenidos por el grupo:


- Tarea 1



- Tarea 2



- Tarea 3




Se analiza la relación entre la 'Cantidad' (número de acciones transaccionadas) y el 'Monto_Efectivo' (valor total de la operación en USD).

El R-cuadrado es de 0.824, lo que nos indica que el 82.4% de la variabilidad en el 'Monto_Efectivo' es explicada por la 'Cantidad' de acciones transaccionadas. Esto convierte a la 'Cantidad' en un predictor relevante del monto efectivo de la operación. Conocer la cantidad de acciones nos permite estimar el dinero que se moverá en una transacción, facilitando planificaciones financieras, estimaciones de montos de transacción e identificación de anomalías.

En coef, la constante ('const') es de 6701.9950, lo que representa el monto de efectivo esperado cuando la cantidad de acciones transaccionadas es cero. Este valor podría interpretarse como un monto base asociado al inicio de una transacción o costos fijos mínimos. Por otro lado, el coef para 'Cantidad' es de 0.8095. Este valor indica que, por cada acción adicional transaccionada, el 'Monto_Efectivo' esperado aumenta en \$0.8095 USD, lo cual establece el precio promedio por acción dentro de esta relación lineal.

Los P-value ($P > |t|$) para 'const' y 'Cantidad' son ambos 0. Esto señala que existe una relación estadísticamente significativa y real entre la variable 'Cantidad' y la variable 'Monto_Efectivo', y que el intercepto ('const') es significativamente diferente de cero. El impacto del número de acciones transaccionadas en el monto efectivo de la operación es confiable y no puede atribuirse a la suerte o a fluctuaciones aleatorias en los datos.



Se establece, por el test de Shapiro-Wilk, que los residuos no siguen una distribución normal. Al tener un valor p menor a 0.05, las inferencias del modelo podrían ser engañosas o no tan confiables.

En el gráfico de "Valores Ajustados vs. Residuos" se observa un patrón no aleatorio, con forma de embudo. Esto indica que la dispersión de los errores es pequeña para valores de predicción bajos, pero muy grande cuando se trata de valores altos. Así, con montos bajos, el modelo es preciso y tiene pocos errores, pero con montos altos, genera incertidumbre y errores considerablemente mayores.

La presencia de este patrón significa que no hay homocedasticidad. Por lo tanto, las estimaciones del modelo no son fiables, y las conclusiones derivadas de ellas tampoco.

Además, se detectan valores atípicos que provocan que el modelo se equivoque en ciertas predicciones, lo que sugiere la existencia de datos erróneos o variables omitidas.

Por consiguiente, podemos concluir que el modelo generado presenta limitaciones significativas, especialmente en lo que respecta a grandes transacciones. No se puede confiar plenamente en sus estimaciones. Se podrían considerar otros modelos, investigar más a fondo el conjunto de datos por si se omitió información relevante, o aplicar transformaciones a las variables para estabilizar los datos.

- Enlace al Google Colab :

<https://colab.research.google.com/drive/1BkAkB1gIMSio32IbNi1QZCES233MtaxU?usp=sharing>

6. Preguntas de Control:

1. **Análisis de Sensibilidad:** Basándose en su variable independiente (X) y dependiente (Y), ¿la pendiente (β_1) calculada tiene sentido lógico con el fenómeno de su región? Justifique cuantitativamente el impacto de un incremento unitario de X en Y.

La pendiente calculada ($\beta_1 = 0.8095$) es lógicamente coherente en el contexto bursátil. Representa que, por cada acción adicional ('Cantidad') transaccionada, el 'Monto_Efectivo' esperado aumenta en aproximadamente \$0. 8095 USD. Es decir, \$0. 8095 es el precio promedio por acción que el modelo estima en esta relación lineal, lo cual es un impacto cuantitativo directo y fundamental para entender la valoración y las estimaciones de transacciones de valores. Da una base clara para el cálculo del valor transaccional.

2. **Inferencia y Significancia:** En el resumen de statsmodels, ¿qué indica el P-value ($\text{Prob} > |t|$) del predictor respecto a la Hipótesis Nula (H_0)? ¿Qué riesgo corre su modelo si este valor supera el umbral de 0.05?

Un P-value de 0 para el predictor 'Cantidad' indica que se rechaza H_0 , que postula que el coeficiente de 'Cantidad' es cero, lo que significaría que no hay una relación lineal significativa. Al rechazar H_0 , confirmamos que el efecto de 'Cantidad' sobre 'Monto_Efectivo' es significativo y no se debe al azar. Si P-value > 0.05 , el modelo correría el riesgo de basar sus predicciones e inferencias en un predictor cuya relación podría ser casual, quitando la confianza en los resultados del modelo para la toma de decisiones de negocio.

3. **Bondad de Ajuste vs. Relación Lineal:** ¿Cómo explica usted la diferencia conceptual entre el Coeficiente de Correlación (r) y el R^2 ? Si el R^2 es bajo (p.ej., < 0.5), ¿qué nos dice sobre la variabilidad de sus datos que el modelo lineal no está logrando capturar?

El Coeficiente de Correlación, 0.9079, mide la fuerza de la relación lineal entre 'Cantidad' y 'Monto_Efectivo'. Un valor cercano a 1 indica una fuerte relación lineal positiva. Por su parte, el R^2 (0.824) dice que tanto la varianza total del 'Monto_Efectivo' es explicada por la 'Cantidad' en el modelo lineal.

La diferencia es que 'r' describe la naturaleza de la relación, mientras ' R^2 ' evalúa cuánto de la variación en la variable dependiente es capturada por el modelo.

Con $R^2 < 0.5$, indicaría que el modelo lineal solo está explicando una pequeña parte de la variabilidad del 'Monto_Efectivo'. Por lo que hay factores adicionales no incluidos o una relación no lineal que impulsan la variabilidad.

4. Límites de la Predicción: ¿Qué riesgos de sesgo o error se introducen al realizar extrapolaciones fuera del dominio de los datos observados? Ilustre con un caso hipotético de su proyecto.

Realizar extrapolaciones fuera del dominio de los datos observados introduce un alto riesgo de sesgo y error. El modelo lineal asume que la relación entre 'Cantidad'-'Monto_Efectivo' se mantiene constante más allá de los valores con los que fue entrenado. Podríamos intentar predecir el 'Monto_Efectivo' para una transacción de 50,000,000 acciones, pero con datos observados que solo llegan hasta 500,000. Factores como descuentos por volumen para órdenes muy grandes, límites de la liquidez del mercado o regulaciones específicas pueden hacer que la relación lineal se rompa, resultando en predicciones irrealistas y decisiones de negocio erróneas.

5. Validación de Supuestos (ABI): Si en su diagnóstico de residuos observa un patrón no aleatorio (por ejemplo, forma de "U" o abanico), ¿por qué es inválido asumir que el modelo es lineal? ¿Qué alternativa sugeriría para ajustar mejor la relación entre X e Y?

Si el diagnóstico de residuos muestra un patrón no aleatorio, como un "embudo", es inválido asumir que el modelo es lineal en su totalidad. Este patrón indica una violación de la homocedasticidad, la varianza constante de los errores, y que el modelo está fallando en sus predicciones para ciertos rangos de 'Cantidad', la relación subyacente es más compleja que una línea recta.

Para ajustar mejor esta relación, se podría considerar transformaciones de variables, modelos de regresión no lineal o regresión ponderada si la heterocedasticidad es el problema mayor, obteniendo estimaciones más fiables.

7. Conclusiones.

Se puede decir que el uso de modelos de regresión lineal necesita de un cuidado y conocimiento sólido para saber interpretar los resultados obtenidos y lo que significan para el dataset. Su mala interpretación puede llevar a obtener resultados erróneos y poco precisos que obstaculicen el trabajo del estudiante o ingeniero, por lo que reconocer las señales que da el modelo y los cambios a realizar son esenciales si se quiere trabajar de manera correcta.

8. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio Evaluado	Puntaje Máximo	Evidencia Esperada
-------------------	----------------	--------------------

1. Modelado Teórico y Correlación	2.0 puntos	Ejecución exitosa de Tarea 1 y 2, mostrando cálculo correcto de r , p -valor y superposición de la recta OLS.
2. Aplicación Predictiva Regional (ABP)	3.0 puntos	Selección coherente de variables X e Y , ajuste del modelo, e interpretación técnica del resumen de statsmodels (especialmente R^2 y β_1).
3. Diagnóstico de Residuos (ABI)	2.5 puntos	Test de Shapiro-Wilk sobre .resid y generación del gráfico "Valores Ajustados vs Residuos", con dictamen de validez.
4. Preguntas de Control	1.5 puntos	Respuestas fundamentadas en celdas Markdown, relacionando la inferencia (\$P>
5. Organización y Estilo	1.0 puntos	Documento estructurado lógicamente. Ecuaciones formateadas en LaTeX. Gráficos con títulos, leyendas y ejes rotulados correctamente.
Total	10.0 puntos	

9. Bibliografía

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Anexos

Enlace al Google Colab :
<https://colab.research.google.com/drive/1BkAkB1gIMSio32IbNi1QZCES233MtaxU?usp=sharing>

Preguntas hechas a la IA de Gemini:

En base a las respuestas que te doy, ¿qué tan acertadas son en relación con el trabajo realizado en el código con el dataset? Dame sugerencias y explicaciones con ellas.

11. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	