



Actividades Práctico-Experimentales

Nro. 013

Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	3
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	013
Título de la Práctica	Análisis Predictivo Multivariado: Regresión Lineal Múltiple y Diagnóstico de Multicolinealidad (VIF)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Grupo A	Isaac Vire Carlos Martinez Erick Rogel Mateo Yanangomez Elvis Guayllas
Fecha	Martes 13 de julio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

- **Construir** un modelo de Regresión Lineal Múltiple integrando varios predictores continuos mediante el método de Mínimos Cuadrados Ordinarios (OLS) en statsmodels.
- **Aplicar** el modelado multivariado al conjunto de datos regional del Proyecto Integrador, seleccionando las variables predictoras más significativas basándose en el R^2 Ajustado y los valores p parciales (ABP).



- **Investigar** y ejecutar pruebas de diagnóstico avanzado, específicamente el Factor de Inflación de la Varianza (VIF), para identificar y mitigar la multicolinealidad estructural en los datos (ABI).

2. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

3. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante descubrirá que predecir el comportamiento de su región usando una sola variable (Semana 13) es impreciso. Deberá combinar múltiples factores (ej. temperatura, humedad y altitud para predecir rendimiento agrícola) y decidir si vale la pena la complejidad adicional del modelo.
- **ABI (Aprendizaje Basado en Investigación):** Indagación sobre el "castigo matemático" que aplica el R^2 Ajustado cuando se añaden variables "basura" al modelo, y cómo descubrir si dos predictores están compitiendo entre sí (Multicolinealidad).
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual con consolidación del modelo final para el Proyecto Integrador en grupos.

Tarea 1: Ajuste del Modelo de Regresión Lineal Múltiple

La Regresión Lineal Múltiple expande la ecuación a un hiperplano de k dimensiones:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \epsilon$$

Abra un nuevo Jupyter Notebook llamado APE_014_RegresionMultiple.ipynb.

Escenario: Predecir el **Tiempo de Compilación de un Software en segundos** (Y) basándonos en las **Líneas de Código** (X_1) y la **Memoria RAM disponible en GB** (X_2).

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sm
```

1. Generación de datos simulados multivariados

```
np.random.seed(42)
n_muestras = 150
```

```
lineas_codigo = np.random.randint(5000, 50000, size=n_muestras) # X1
ram_disponible = np.random.uniform(4.0, 32.0, size=n_muestras) # X2
```

$Y = B_0 + B_1 * X_1 + B_2 * X_2 + \text{Error}$

A más líneas, más tiempo (+). A más RAM, menos tiempo (-)

```
tiempo_compilacion = 15.0 + (0.002 * lineas_codigo) - (1.5 * ram_disponible) +
np.random.normal(0, 15, size=n_muestras)
```

```
df_simulado = pd.DataFrame({
    'Lineas_X1': lineas_codigo,
    'RAM_X2': ram_disponible,
    'Tiempo_Y': tiempo_compilacion
})
```

2. Configuración de la matriz de características X y el vector Y

```
X_multi = df_simulado[['Lineas_X1', 'RAM_X2']]
Y_multi = df_simulado['Tiempo_Y']
```

Añadir la constante (Intercepto B_0)

```
X_multi_sm = sm.add_constant(X_multi)
```

3. Ajuste del Modelo OLS Múltiple

```
modelo_multiple = sm.OLS(Y_multi, X_multi_sm).fit()
```

Imprimir el resumen estadístico

```
print(modelo_multiple.summary())
```



Tarea 2: Hito del Proyecto - Modelado Predictivo Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Defina su Variable Respuesta (Y) y seleccione **al menos dos** Variables Predictoras ($X_1, X_2, \dots, X_k$).
3. Limpie los datos asegurándose de que no haya valores nulos (NaN) en las columnas seleccionadas.
4. Entrene un modelo OLS Múltiple como en la Tarea 1.
5. **Análisis Crítico:** Redacte un análisis en Markdown interpretando específicamente los coeficientes β_i en el contexto de su problema regional. Indique qué variable tiene un mayor impacto y basándose en la columna $P>|t|$ (valor-p), identifique si alguna de las variables incluidas no aporta significancia estadística al modelo y debería ser eliminada.

Tarea 3: Visualización de Relaciones (Pairplot y Heatmap)

Antes de incluir variables a ciegas, un ingeniero debe inspeccionar las correlaciones cruzadas.

```
# Matriz de Correlación
```

```
matriz_corr = df_simulado.corr()
```

```
# Visualización mediante Heatmap
```

```
plt.figure(figsize=(6, 4))
```

```
sns.heatmap(matriz_corr, annot=True, cmap='coolwarm', fmt=".2f", vmin=-1, vmax=1)
```

```
plt.title('Mapa de Calor: Correlaciones Multivariadas')
```

```
plt.show()
```

```
# Visualización de dispersiones múltiples
```

```
sns.pairplot(df_simulado, kind='reg', plot_kws={'line_kws':{'color':'red'}})
```

```
plt.suptitle('Pairplot: Relaciones Bivariadas', y=1.02)
```

```
plt.show()
```

Aplique este mismo bloque de código a las variables de su dataset regional (Tarea 2) y documente si observa que dos de sus variables predictoras X están altamente correlacionadas entre sí.

Tarea 4: ABI - Diagnóstico de Multicolinealidad (VIF)

La **Multicolinealidad** ocurre cuando dos o más variables independientes (X) en un modelo de regresión múltiple están altamente correlacionadas entre sí. Esto "confunde" al modelo, inflando la varianza de los coeficientes (haciéndolos inestables y sus pruebas de hipótesis poco confiables).

1. Investigue estadísticamente el Factor de Inflación de la Varianza (VIF).

2. Ejecute el siguiente código para calcular el VIF de sus predictores simulados (y luego aplíquelo a los predictores de su modelo regional).

```
from statsmodels.stats.outliers_influence import variance_inflation_factor

# Se calcula el VIF para cada variable independiente (incluyendo la constante)
# VIF = 1 / (1 - R_i^2)

vif_data = pd.DataFrame()
vif_data["Variable"] = X_multi_sm.columns
vif_data["VIF"] = [variance_inflation_factor(X_multi_sm.values, i)
                    for i in range(X_multi_sm.shape[1])]

print("\n--- Análisis de Multicolinealidad ---")
print(vif_data)
```

5. Resultados obtenidos por el grupo:

- Tarea 1

OLS Regression Results						
Dep. Variable:	Tiempo_Y	R-squared:	0.791			
Model:	OLS	Adj. R-squared:	0.788			
Method:	Least Squares	F-statistic:	278.4			
Date:	Mon, 20 Jul 2026	Prob (F-statistic):	1.02e-50			
Time:	03:02:15	Log-Likelihood:	-617.66			
No. Observations:	150	AIC:	1241.			
Df Residuals:	147	BIC:	1250.			
Df Model:	2					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	21.1081	3.866	5.459	0.000	13.467	28.749
lineas_X1	0.0019	8.86e-05	21.410	0.000	0.002	0.002
RAM_X2	-1.6664	0.158	-10.526	0.000	-1.979	-1.354
Omnibus:	2.687	Durbin-Watson:	2.075			
Prob(Omnibus):	0.261	Jarque-Bera (JB):	2.311			
Skew:	0.296	Prob(JB):	0.315			
Kurtosis:	3.138	Cond. No.	9.34e+04			

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

[2] The condition number is large, 9.34e+04. This might indicate that there are strong multicollinearity or other numerical problems.

- Tarea 2



```
OLS Regression Results
=====
Dep. Variable:      Monto_Efectivo      R-squared:      0.824
Model:              OLS                Adj. R-squared: 0.824
Method:             Least Squares       F-statistic:    6.841e+04
Date:               Mon, 20 Jul 2026     Prob (F-statistic): 0.00
Time:               03:07:36            Log-Likelihood: -3.5653e+05
No. Observations:   29131              AIC:            7.131e+05
Df Residuals:       29128              BIC:            7.131e+05
Df Model:            2
Covariance Type:    nonrobust
=====
```

	coef	std err	t	P> t	[0.025	0.975]
const	6345.9060	298.141	21.285	0.000	5761.535	6930.277
Cantidad	0.8097	0.002	369.888	0.000	0.805	0.814
Precio	8.3218	1.217	6.839	0.000	5.937	10.707

Omnibus:	32735.777	Durbin-Watson:	1.878
Prob(Omnibus):	0.000	Jarque-Bera (JB):	8518027396.443
Skew:	3.786	Prob(JB):	0.00
Kurtosis:	2652.084	Cond. No.	1.36e+05


Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 1.36e+05. This might indicate that there are strong multicollinearity or other numerical problems.


Los coeficientes representan el cambio esperado en el Monto Efectivo por cada unidad de cambio en una variable predictora, manteniendo la otra constante. B1 indica cuanto aumenta el capital movilizad por acción adicional realizada. B2 representa el impacto del valor de mercado de la acción sobre el monto total.

El estadístico t dice cuantas desviaciones estándar está el coeficiente de cero, un valor más alto implica mayor impacto. Cantidad tiene un estadístico t mayor que el estadístico t de Precio. Entonces Cantidad tiene un impacto mayor en el Monto_Efectivo dentro del modelo. Aun así, ambas variables son significativas.

El valor P>|t| es cero tanto para Cantidad como para Precio. Ambas variables son estadísticamente significativas y ayudan al modelo a predecir el Monto_Efectivo.

- Tarea 3





No hay una correlación alta entre cantidad y precio, son relativamente independientes entre si, lo que permitirá al modelo de regresión lineal estimar sus coeficientes de manera más estable y confiable

Hay una correlación alta y positiva de 0.907855, entre Monto_Efectivo y Cantidad. Esto indica que a medida que la Cantidad de acciones transaccionadas aumenta, el Monto_Efectivo también tiende a aumentar de manera fuerte y lineal.

Hay una correlación baja y positiva de 0.007562, entre Monto_Efectivo y Precio. Esto sugiere que la relación lineal entre el Precio y el Monto_Efectivo es prácticamente inexistente o muy débil en este conjunto de datos. Es la Cantidad la que domina la variabilidad de Monto_Efectivo en este contexto, lo cual se alinea con la alta correlación entre Cantidad y Monto_Efectivo.

- Tarea 4

```

--- ANÁLISIS DE MULTICOLINEALIDAD OPTIMIZADO (Dataset BV6) ---
Variable      VIF
1 Cantidad  1.000103
2 Precio    1.000103

--- Dictamen de Ingeniería ---
Cantidad: VIF=1.00 → Independencia validada. Sin evidencia de multicolinealidad.
Precio: VIF=1.00 → Independencia validada. Sin evidencia de multicolinealidad.
  
```

El VIF nos dice cuánto se ha inflado la varianza de un coeficiente de regresión estimado debido a la colinealidad con otras variables predictoras en el modelo.

Ambos valores de VIF son extremadamente cercanos a 1.00. Estos resultados indican:

Que no hay evidencia de multicolinealidad entre Cantidad y Precio. Por lo que los coeficientes estimados para Cantidad y Precio en un modelo de regresión lineal múltiple serán estables y sus errores estándar no estarán inflados debido a la intercorrelación entre ellas. Podemos interpretar con confianza la contribución única de cada variable al Monto_Efectivo.

- Enlace al Google Colab: <https://colab.research.google.com/drive/1dJ2tjZQzRRT6A3wTLDD7oXuYZ6i4UY-b?usp=sharing>

6. Preguntas de Control:

1. **Considerando la naturaleza de la causalidad, ¿cómo la lógica de 'mantener las demás variables constantes' permite aislar el efecto de un factor específico en un fenómeno complejo, y qué limitaciones filosóficas impone esto a la realidad?**

El principio de aislar variables es indispensable para establecer relaciones de causa y efecto, ya que nos permite evaluar el impacto de un único factor al neutralizar las interferencias externas. Sin embargo, desde una perspectiva filosófica, esto supone admitir que la ciencia inevitablemente simplifica un mundo sumamente complejo. Debido a la constante interacción entre múltiples elementos, comprobar una causalidad perfecta resulta casi inalcanzable. Por lo tanto, el conocimiento científico debe interpretarse como un conjunto de representaciones prácticas y aproximadas, y no como un reflejo exacto y total del universo.

2. **Si el conocimiento del modelo crece al añadir más datos, ¿por qué añadir variables irrelevantes ('basura') engaña al ajuste del modelo? ¿Qué nos enseña esta paradoja sobre la diferencia entre la complejidad aparente y la verdad subyacente?**

Cuando añadimos más datos, esperamos que el modelo capture más información subyacente que describa la relación entre las variables. Sin embargo, las variables irrelevantes solo aportan ruido. Si bien aumentamos el volumen de datos, gran parte de esa nueva información es engañosa o no contribuye a entender el fenómeno que intentamos modelar.

El modelo puede empezar a capturar patrones aleatorios y ruido presente en las variables irrelevantes. El modelo se sobre ajusta a las particularidades y anomalías del conjunto de datos de entrenamiento, incluyendo el ruido introducido por esas variables basura. El modelo se vuelve excesivamente complejo y su rendimiento se deteriora drásticamente con datos nuevos o no vistos.

- Complejidad Aparente: Al añadir más variables, el modelo se vuelve estructuralmente más complejo. Tiene más parámetros que ajustar, lo que le da más capacidad para encontrar patrones. Esto puede dar la idea de que el modelo es más sofisticado y está aprendiendo más.
- Verdad Subyacente: Sin embargo, la verdad subyacente del fenómeno que estamos modelando es, por definición, más simple. Al incorporar variables irrelevantes, el modelo se desvía de la verdad. Está persiguiendo conexiones aleatorias, lo que lo aleja de una representación fiel de la realidad.

El conocimiento del modelo no se mide solo por la cantidad de datos o variables que procesa, sino por su capacidad para discernir la señal del ruido y capturar la verdadera estructura de los datos de manera generalizable. Un modelo con menos variables pero todas relevantes es a menudo mucho más potente, interpretable y robusto que un modelo inflado con información irrelevante.

3. **Ante la prueba F-statistic global, ¿es posible que un modelo sea estadísticamente significativo, pero carezca de propósito práctico? ¿Cómo se reconcilia la precisión**



matemática con la incertidumbre del mundo real en la toma de decisiones de ingeniería?

Sí, es posible que un modelo sea estadísticamente significativo y aun así no tenga mucha utilidad práctica. La prueba F solo indica que existe una relación entre las variables y que no se debe al azar, pero eso no significa que el modelo haga buenas predicciones o sea útil para tomar decisiones. Por ejemplo, un modelo puede tener un p-valor muy pequeño, pero explicar muy poca variabilidad de los datos. En ingeniería, creemos que la precisión matemática debe complementarse con el análisis del contexto, el tamaño del efecto, el margen de error y la experiencia, ya que los modelos son una aproximación de la realidad y siempre existe incertidumbre.

4. Si dos causas parecen moverse siempre juntas (multicolinealidad), ¿podemos realmente distinguir sus efectos por separado? ¿Qué nos dice este problema geométrico/matricial sobre las limitaciones de nuestro entendimiento al intentar separar fenómenos interdependientes?

Cuando dos o más variables predictoras parecen moverse siempre juntas no podemos distinguir sus efectos de manera fiable por separado.

El problema ocurre cuando las variables independientes están altamente correlacionadas entre sí. Esto confunde al modelo, lo que resulta en coeficientes inestables y pruebas de hipótesis poco fiables, la multicolinealidad es un recordatorio de que la estadística no puede inventar información que no está presente en los datos. Si los datos no muestran las variables moviéndose de forma independiente, el modelo simplemente no puede discernir sus efectos individuales con precisión.

Este problema demuestra que nuestros modelos son limitados al intentar separar fenómenos interdependientes porque, para aislar el efecto de una causa, el modelo necesita variación independiente. Si dos fenómenos siempre ocurren juntos, el modelo no sabe qué sucede si una cambia y la otra no.

5. Ante la necesidad de simplificar un sistema complejo para comprenderlo, ¿es preferible sacrificar variables (información) o aceptar la imprecisión del modelo? ¿Qué define, bajo su criterio, a un 'buen' modelo para la ingeniería?

Se sacrifican variables siempre que su impacto no sea tan perjudicial y esté dentro del margen de error tolerable del proyecto. Se puede tomar en cuenta que si alguna variable se la elimina y el caso de estudio se pierde y no se llega al punto de investigación que se requiere ahí sí se puede aceptar la imprecisión del modelo. Los puntos fundamentales que definen un buen modelo son:

Parsimonia (Principio de Ockham): Un equilibrio óptimo entre simplicidad y precisión. Logra explicar o predecir el fenómeno con la menor cantidad posible de parámetros y complejidad computacional.



Dominio de validez delimitado: Un modelo robusto define explícitamente sus condiciones contorno y supuestos. Conocer sus límites previene fallas.

Utilidad predictiva y costo de decisión: La precisión del modelo debe ser proporcional al riesgo involucrado. Un modelo es "bueno" si el margen de error que introduce es inferior al factor de seguridad del diseño y su costo de desarrollo es menor al beneficio que aporta.

7. Conclusiones.

Se ha visto los aspectos fundamentales del modelado de regresión lineal múltiple, abarcando desde la identificación de variables predictoras significativas hasta el crucial diagnóstico y manejo de la multicolinealidad. Se tiene que evaluar el impacto relativo de cada variable independiente sobre la variable respuesta a través de sus estadísticos, así como su significancia estadística para asegurar que todas las variables incluidas contribuyen de manera valiosa al modelo. Los análisis de correlación y los Factores de Inflación de la Varianza (VIF) son herramientas útiles para identificar y confirmar la ausencia de multicolinealidad entre las variables predictoras, asegurando estabilidad y fiabilidad de los coeficientes estimados en el modelo. La comprensión de cómo las interacciones entre las variables pueden afectar los resultados del modelo y la habilidad para mitigar problemas como la multicolinealidad son cosas importantes que considerar.

8. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio	Puntaje	Descripción
Implementación Técnica	3.0 pts	Ejecución correcta del modelo (simulado y regional) y limpieza/documentación del código.
Análisis y Diagnóstico	5.0 pts	Interpretación de coeficientes, diagnóstico efectivo de multicolinealidad (VIF) y visualización.
Reflexión Crítica	2.0 pts	Calidad y profundidad en las respuestas a las preguntas de control (enfoque aristotélico).
Total	10.0 pts	



9. Bibliografía

- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.
- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.
- [3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].

10. Anexos

Enlace al Google Colab:
<https://colab.research.google.com/drive/1dJ2tjZQzRRT6A3wTLDD7oXuYZ6i4UY-b?usp=sharing>

Preguntas hechas a la IA de Gemini:

Dame una respuesta en base a la pregunta dada, que complementen mi respuesta. Da una explicación detallada del porque detrás de esa respuesta y como se combina con mi respuesta.

11. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	