

Guía de Actividades Práctico- Experimentales Nro. 014

Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	3
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	014
Título de la Práctica	Modelado Probabilístico Avanzado: Regresión Logística, Clasificación Binaria y Matriz de Confusión
Nombre del Docente	Cristian Ramiro Narváez Guillén
Grupo A	Isaac Vire Carlos Martinez Erick Rogel Mateo Yanangomez Elvis Guayllas
Fecha	Martes 20 de julio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

-

- Construir modelos probabilísticos para variables de respuesta binaria utilizando la Función Sigmoide y la Estimación de Máxima Verosimilitud (MLE) a través de statsmodels y scikit-learn.
- Aplicar el modelo de regresión logística al conjunto de datos regional del Proyecto Integrador para predecir la probabilidad de que ocurra un evento de interés, evaluando su precisión empírica (ABP).
- Investigar y demostrar computacionalmente el efecto de modificar el umbral de decisión probabilística (cutoff) sobre las tasas de Error Tipo I y Tipo II mediante el análisis de la Matriz de Confusión (ABI).

2. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

3. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- ABP (Aprendizaje Basado en Problemas): El estudiante descubrirá que predecir el comportamiento de su región usando una sola variable (Semana 13) es impreciso. Deberá combinar múltiples factores (ej. temperatura, humedad y altitud para predecir rendimiento agrícola) y decidir si vale la pena la complejidad adicional del modelo.
- ABI (Aprendizaje Basado en Investigación): Indagación sobre el "castigo matemático" que aplica el R^2 Ajustado cuando se añaden variables "basura" al modelo, y cómo descubrir si dos predictores están compitiendo entre sí (Multicolinealidad).
- Duración sugerida: 120 min. (presencial).
- Modalidad: Ejecución técnica individual con consolidación del modelo final para el Proyecto Integrador en grupos.

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante ya no predice un valor continuo (ej. "cuánto lloverá"), sino la probabilidad de ocurrencia de una condición crítica (ej. "¿Habrá inundación? 1=Sí, 0=No"). Deberá transformar un problema de su región en una pregunta de clasificación binaria.

- **ABI (Aprendizaje Basado en Investigación):** Indagación matemática sobre por qué OLS (Mínimos Cuadrados Ordinarios) falla estrepitosamente al predecir categorías, obligando a la introducción de la función Sigmoide y el pseudo- R^2 .
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual, con interpretación y ajuste de umbrales en los grupos del Proyecto Integrador.

Tarea 1: Fundamentos de la Regresión Logística (Función Sigmoide)

A diferencia de la regresión lineal, la regresión logística estima la probabilidad $P(Y = 1|X)$. Para garantizar que el resultado esté estrictamente acotado entre $[0, 1]$, se utiliza la función logística (Sigmoide):

1.

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}$$

Abra un nuevo Jupyter Notebook llamado APE_015_Logistica.ipynb.

2. Escenario: Predecir la Caída de un Servidor (1 = Sí, 0 = No)

basándonos en la Temperatura de la CPU en °C (X_1).

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import statsmodels.api as sm
```

```
# 1. Generación de datos simulados (Clasificación Binaria)
np.random.seed(42)
n_muestras = 200
```

```
# Variable predictora: Temperatura CPU (entre 40 y 90 grados)
temp_cpu = np.random.uniform(40, 90, size=n_muestras)
```

```
# Generar variable binaria probabilística (A mayor temperatura, mayor probabilidad de falla)
```



```
z = -10 + 0.15 * temp_cpu # Ecuación lineal (Log-Odds)
probabilidad_falla = 1 / (1 + np.exp(-z)) # Transformación Sigmoide

# Variable respuesta binaria (0 = OK, 1 = Falla) basada en la probabilidad
falla_servidor = np.random.binomial(1, p=probabilidad_falla)

df_sim = pd.DataFrame({'Temp_CPU': temp_cpu, 'Falla': falla_servidor})

# 2. Ajuste del Modelo Logístico (Logit)
X_log = sm.add_constant(df_sim['Temp_CPU']) Y_log
= df_sim['Falla']

# Entrenamiento usando MLE (Maximum Likelihood Estimation) modelo_logit
= sm.Logit(Y_log, X_log).fit()

print(modelo_logit.summary())

# 3. Visualización de la Curva Sigmoide x_rango =
np.linspace(30, 100, 300) x_rango_sm =
sm.add_constant(x_rango)
y_pred_prob = modelo_logit.predict(x_rango_sm)

plt.figure(figsize=(8, 5))
sns.scatterplot(x='Temp_CPU', y='Falla', data=df_sim, color='black', alpha=0.5,
label='Datos (0 o 1)')
plt.plot(x_rango, y_pred_prob, color='red', linewidth=2, label='Curva de
Probabilidad Logística')
plt.axhline(0.5, color='gray', linestyle='--', label='Umbral de Decisión (50%)')
plt.title('Regresión Logística: Probabilidad de Falla vs Temperatura')
plt.xlabel('Temperatura CPU (°C)')
plt.ylabel('Probabilidad de Falla P(Y=1)') plt.legend()
plt.show()
```

Tarea 2: Hito del Proyecto - Predicción Dicotómica Regional (ABP)

1. Importe su dataset regional mediante pandas.
2. Ingeniería de Características: Seleccione una variable continua de interés y binarícela.

- Ejemplo: Si tiene "Ingresos", cree una nueva columna Alta_Rentabilidad donde 1 si $\text{Ingresos} > \text{Promedio}$, y 0 si $\text{Ingresos} \leq \text{Promedio}$.

3. Seleccione al menos dos variables predictoras (X_1, X_2) para predecir esta nueva variable binaria.
4. Ajuste el modelo `sm.Logit()` e imprima el resumen.
5. Interprete los resultados: ¿Qué variable(s) incrementa(n) estadísticamente la probabilidad de que ocurra su evento (coeficiente positivo y valor-p < 0.05)?

Tarea 3: Evaluación del Modelo (Matriz de Confusión)

Un modelo de clasificación no se evalúa con el R^2 , sino contando cuántos aciertos y errores cometió.

1. Utilice scikit-learn para calcular las predicciones y generar la Matriz de Confusión del modelo simulado en la Tarea 1.

```
from sklearn.metrics import confusion_matrix, accuracy_score,
ConfusionMatrixDisplay
```

```
# El modelo devuelve probabilidades continuas [0, 1]. Debemos convertirlas a 0 o 1
# usando un umbral (threshold) estándar de 0.5 (50%)
probabilidades = modelo_logit.predict(X_log)
predicciones_clase = (probabilidades >= 0.5).astype(int)
```

```
# Cálculo de la Matriz de Confusión
```

```
cm = confusion_matrix(Y_log, predicciones_clase) exactitud =
accuracy_score(Y_log, predicciones_clase)
```

```
print(f"\n--- Evaluación del Modelo Probabilístico ---")
print(f"Exactitud Global (Accuracy): {exactitud*100:.2f}%")
```

```
# Visualización
```

```
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=['OK (0)', 'Falla
(1)'])
disp.plot(cmap='Blues', values_format='d')
```

```
plt.title('Matriz de Confusión (Umbral 0.5)')
plt.show()
```

Aplique este mismo proceso para evaluar el modelo de su Proyecto Integrador (Tarea 2).

Tarea 4: ABI - El Análisis del Umbral (Thresholding) y Falsos Positivos


Por defecto, Python asume que si $P(Y = 1) \geq 0.50$, la clasificación es 1. Sin embargo, en ingeniería, el costo de un "Falso Negativo" (predecir que el servidor no fallará y que termine explotando) suele ser mucho mayor que un "Falso Positivo" (ir a revisar un servidor que estaba bien).

1. Investigue cómo alterar el umbral modifica la Matriz de Confusión.
2. Cree un bloque de código que recalculé y muestre la matriz de confusión (o simplemente los valores de Falsos Positivos y Falsos Negativos) utilizando un umbral estricto conservador del 0.20 (es decir, clasificar como 'Falla' si la probabilidad es apenas $\geq 20\%$).
3. Redacte un análisis de qué le sucedió a los Falsos Positivos frente a los Falsos Negativos, y decida qué umbral (0.50 o 0.20) recomendaría para las políticas públicas o de ingeniería en su proyecto regional.

5. Resultados esperados:

Al finalizar esta práctica, el estudiante será capaz de:

- Tarea 1



- Tarea 2

```

*** Umbral de Binarización (Promedio): $13,171.56 USD
Distribución de Clases:
Monto_Alto
0    0.834438
1    0.165562
Name: proportion, dtype: float64
Optimization terminated successfully.
Current function value: 0.288096
Iterations 10

--- RESUMEN DEL MODELO LOGÍSTICO ---
Logit Regression Results
=====
Dep. Variable:      Monto_Alto    No. Observations:      29131
Model:              Logit         Df Residuals:              29128
Method:              MLE          Df Model:                  2
Date:               Mon, 20 Jul 2026    Pseudo R-squ.:          0.5363
Time:               16:29:41          Log-Likelihood:         -6062.0
converged:           True              LL-Null:              -13073.
Covariance Type:     nonrobust         LLR p-value:            0.000
=====
               coef    std err          z      P>|z|    [0.025    0.975]
-----
const        -3.8540     0.041    -95.118     0.000    -3.933    -3.775
Cantidad       0.0004    5.54e-06    68.490     0.000     0.000     0.000
Precio        0.0013    6.73e-05    19.464     0.000     0.001     0.001
=====


```

En una regresión logística binaria, el modelo estima el logaritmo de la razón de probabilidades (log-odds) de que ocurra el evento $Y=1$. Es decir, busca una relación lineal entre las variables predictoras y el log-odds de que una transacción sea de 'Alto Valor' ($Y=1$, cuando el Monto_Efectivo es superior al promedio de todas las transacciones) o de 'Bajo Valor' ($Y=0$, cuando es inferior o igual). Dado que los coeficientes de 'Cantidad' y 'Precio' son positivos, se infiere que un incremento en cualquiera de estas variables debería elevar la probabilidad de que la operación sea de 'Alto Valor'.

Con respecto al valor $P>|z|$, tanto para 'Cantidad' como para 'Precio', el valor es muy cercano a 0. Esto indica que el volumen negociado y la valoración de la acción son factores determinantes para clasificar el Monto_Efectivo de las operaciones bursátiles en la región.

- Tarea 3

Del proyecto integrador




En la matriz de confusión, el modelo clasifica correctamente 23860 transacciones como de "Bajo Valor". Además, 2965 transacciones son clasificadas correctamente como de "Alto Valor". Los otros dos recuadros representan los falsos positivos (transacciones de bajo valor clasificadas erróneamente como alto valor) y los falsos negativos (transacciones de alto valor clasificadas erróneamente como bajo valor).

Un "accuracy" alto sugiere que las variables 'Precio' y 'Cantidad' son predictores sólidos para categorizar el valor de las operaciones.

Sin embargo, con un "accuracy" alto y un dataset desbalanceado, podemos decir que el modelo podría estar sesgado hacia la predicción de la clase mayoritaria.

- Tarea 4



Enlace al Google Colab:

https://colab.research.google.com/drive/1UPedjk43YW96d_12iOooVB3n1zGmHYTv?usp=sharing

6. Preguntas de Control:

- **¿Cuál es la esencia matemática de transformar una probabilidad en Log-Odds, y por qué este cambio de dominio es fundamental para el entendimiento de la causalidad probabilística?**

La probabilidad no se comporta de forma normal cuando intentamos ver cómo la afectan otros factores. Por ejemplo, un mismo cambio de temperatura no afecta igual a la probabilidad si ya es muy baja que si ya es muy alta.

Para solucionar esto, está el 'Log-Odds'. Primero, convertimos la probabilidad en 'Odds' (que compara las probabilidades de que algo pase con las de que no pase). Luego, a esos 'Odds' les sacamos el logaritmo. Se endereza la probabilidad y en lugar de estar entre 0 y 1, sus valores pueden ir en una línea recta, desde números negativos muy grandes hasta números positivos muy grandes. Esto nos permite ver cómo cada factor suma o resta de forma directa y constante a esta versión enderezada de la probabilidad.

Fundamental para entender la causalidad probabilística porque nos permite cuantificar la influencia de cada factor de forma clara. Si un factor suma a los Log-Odds, sabemos que aumenta la probabilidad de falla. Si resta, la disminuye. Esto nos da una medida muy útil y sencilla de cómo los diferentes elementos influyen en la posibilidad de que un evento ocurra.

- **¿Por qué la naturaleza del fenómeno (binario) nos obliga a abandonar la medida clásica de bondad de ajuste (R^2) y adoptar el Pseudo R^2 de McFadden, y qué nos dice este cambio sobre la relación entre la realidad y la**

medición?

La medida clásica de bondad de ajuste R^2 no se usa para la regresión logística binaria porque el R^2 está hecho para modelos lineales con respuesta continuas y normalmente distribuidas. En un modelo binario, la respuesta es 0 o 1, y el modelo logístico predice una probabilidad entre 0 y 1, no un valor exacto. Aplicar R^2 a estos datos resultaría en un valor bajo y poco reales.

Por ello, se recurre al Pseudo R^2 de McFadden, se basa en la comparación de la usabilidad del modelo con las predicciones frente a la de un modelo que da predicciones aleatorias, indicando cuánto mejor es el modelo propuesto para explicar la probabilidad de un evento binario.

La medición debe adaptarse a la naturaleza del fenómeno estudiado. Hay eventos discretos y relaciones no lineales, y las herramientas de análisis deben ser lo suficientemente flexibles para representarlos. El Pseudo R^2 de McFadden implica que la bondad de un modelo para fenómenos binarios se mide por cuán efectivamente mejora la capacidad de predecir la ocurrencia o no ocurrencia de un evento en comparación con una predicción aleatoria.

- **Ante un caso de incertidumbre total (predicción 0.5), ¿de qué manera la estructura del modelo intenta forzar una decisión binaria, y qué riesgos enfrentamos al ignorar la zona gris de la probabilidad?**

El modelo simplemente la convierte en un resultado categórico al imponer un punto de corte. Por esta razón, en escenarios críticos lo ideal es evaluar el espectro probabilístico en su totalidad, definir un margen de duda y, frente a predicciones que rondan el 0.5, requerir datos complementarios o una revisión exhaustiva antes de emitir un fallo.

- **¿Cuál es el conflicto esencial entre la sensibilidad y la especificidad, y cómo la elección de un umbral refleja los valores éticos y técnicos subyacentes en una decisión de ingeniería?**

El conflicto entre la sensibilidad y la especificidad está en que no se puede maximizar ambas al mismo tiempo. Si se busca detectar la mayor cantidad de casos positivos, aumentará la sensibilidad, pero también habrá más falsos positivos. En cambio, si se prioriza la especificidad, se reducen los falsos positivos, aunque existe el riesgo de no detectar algunos casos que realmente sí eran positivos. Por esta razón, la elección del umbral depende del contexto y de las consecuencias que tenga cometer cada tipo de error. En problemas de ingeniería, donde una falla puede generar daños importantes, suele ser más conveniente aceptar algunos falsos positivos antes que dejar pasar una falla real. De esta manera, la decisión refleja tanto criterios técnicos como la responsabilidad de reducir los riesgos.

- **¿Cuál es el propósito final de predecir probabilidades en lugar de estados binarios rígidos, y cómo esta distinción transforma nuestra capacidad de intervenir en la realidad?**

El principal objetivo de calcular probabilidades es estimar qué tan posible es que ocurra un determinado evento. En lugar de afirmar que algo sucederá o no, este método permite expresar el nivel de posibilidad de que ocurra, ya que en la vida cotidiana existen muchos factores que no pueden conocerse con total certeza. Por ejemplo, en el área de la salud no es correcto asegurar que una persona sufrirá un ataque al corazón. Es más adecuado indicar que tiene una determinada probabilidad de padecerlo en los próximos años. De esta manera, las decisiones se toman con base en la información disponible y no en suposiciones o certezas absolutas.

2. ¿Por qué es útil conocer las probabilidades?

Porque ayuda a:

- Conocer la probabilidad de que ocurra un evento permite analizar si es conveniente actuar antes de que aparezca un problema. Además de considerar la posibilidad de que suceda, también se evalúan las consecuencias que podría tener. Por ejemplo, aunque la posibilidad de que un reactor nuclear falle sea muy baja, las consecuencias serían muy graves. Por esta razón, es necesario invertir en medidas de seguridad para prevenir cualquier accidente.
- Da prioridad a los casos más importantes. Las probabilidades ayudan a identificar qué situaciones necesitan mayor atención. Así, los recursos disponibles pueden utilizarse de una forma más eficiente. En el área de la salud, los médicos pueden realizar más controles a las personas que tienen mayor riesgo de desarrollar una enfermedad. De igual manera, los bancos pueden revisar con mayor cuidado las transacciones que presentan una alta probabilidad de fraude, mientras que las demás continúan su proceso normal.

7. Conclusiones.

Hemos usado la regresión logística para predecir si un evento binario ocurre o no, como una falla de CPU o si una transacción es de alto valor. Este modelo nos da una probabilidad y luego usamos un punto de corte (generalmente 0.5) para decidir si clasificarlo como sí (falla/alto valor) o no (normal/bajo valor). Para ver qué tan bien predice el modelo y dónde se equivoca, usamos una matriz de confusión. Nos muestra cuántas veces acertó y cuántas se equivocó en cada categoría.

La regresión logística nos ayuda a tomar decisiones binarias basadas en probabilidades, y la matriz de confusión es nuestra herramienta clave para entender la calidad de esas decisiones, ayudándonos a saber si el modelo es bueno para detectar lo que nos interesa, incluso si a veces se equivoca un poco en el otro sentido. Si necesitamos que el modelo sea más sensible a detectar un tipo de evento, podemos ajustar el punto de corte, cambiando a 0.20.

8. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio	Puntaje	Descripción
Implementación Técnica	3.0 pts	Ejecución correcta del modelo (simulado y regional) y limpieza/documentación del código.
Análisis y Diagnóstico	5.0 pts	Interpretación de coeficientes, diagnóstico efectivo de multicolinealidad (VIF) y visualización.
Reflexión Crítica	2.0 pts	Calidad y profundidad en las respuestas a las preguntas de control (enfoque aristotélico).
Total	10.0 pts	



9. Bibliografía

- [1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

- [2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

- [3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].



10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	

11. Anexos

Enlace al Google Colab:

https://colab.research.google.com/drive/1UPedjk43YW96d_12iOooVB3n1zGmHYTv?usp=sharing