



Actividades Práctico-Experimentales

Nro. 015

Datos Generales

Asignatura	Teoría de la Distribución y Probabilidad
Ciclo	2do "A"
Unidad	3
Resultado de aprendizaje de la unidad	Comprende los conceptos de variable aleatoria multidimensional y distribución de probabilidad asociada, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	015
Título de la Práctica	Evaluación Avanzada de Modelos: Curva ROC, Métrica AUC y Validación Cruzada (K-Fold)
Nombre del Docente	Cristian Ramiro Narváez Guillén
Grupo A	Isaac Vire Carlos Martinez Erick Rogel Mateo Yanangomez Elvis Guayllas
Fecha	Martes 27 de julio del 2026
Horario	11h30 – 13h30
Lugar	EVA Aula
Tiempo planificado en el Sílabo	2 horas

1. Objetivo(s) de la Práctica:

- **Cuantificar** el rendimiento global de un clasificador binario a través de múltiples umbrales de decisión trazando la Curva de Característica Operativa del Receptor (ROC) y calculando el Área Bajo la Curva (AUC) con scikit-learn.
- **Consolidar** y evaluar de forma definitiva el modelo probabilístico regional del Proyecto Integrador, preparando los artefactos técnicos y visuales para su exposición final (ABP).
- **Investigar** y ejecutar algoritmos de Validación Cruzada (K-Fold) para mitigar el sesgo estadístico introducido por particiones únicas de datos (Train/Test Split), previniendo el sobreajuste (ABI).



2. Materiales y reactivos:

- Entorno de desarrollo interactivo (Jupyter Notebook, Google Colab o Anaconda).
- Librerías de Python preinstaladas: numpy, pandas, scipy.stats, matplotlib, seaborn.
- Dataset regional del Proyecto Integrador limpio y validado.
- Conexión a Internet estable y continua.
- Navegador web actualizado.x|

3. Equipos y herramientas

- Recursos físicos: Aula de Computación.
- Computadora personal o portátil (PC o Laptop):
- Sistema operativo: Windows, Linux o macOS.
- Procesador: mínimo 2 núcleos (recomendado 4).
- Memoria RAM: mínimo 4 GB (recomendado 8 GB para manipulación de datasets con pandas).

4. Procedimiento / Metodología

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante descubrirá que predecir el comportamiento de su región usando una sola variable (Semana 13) es impreciso. Deberá combinar múltiples factores (ej. temperatura, humedad y altitud para predecir rendimiento agrícola) y decidir si vale la pena la complejidad adicional del modelo.
- **ABI (Aprendizaje Basado en Investigación):** Indagación sobre el "castigo matemático" que aplica el R^2 Ajustado cuando se añaden variables "basura" al modelo, y cómo descubrir si dos predictores están compitiendo entre sí (Multicolinealidad).
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual con consolidación del modelo final para el Proyecto Integrador en grupos.

Enfoque PID-2025:

- **ABP (Aprendizaje Basado en Problemas):** El estudiante resolverá el desafío de empaquetar todo su análisis de ciclo en un producto coherente. Deberá demostrar que su modelo de predicción regional funciona consistentemente y no fue fruto de la casualidad estadística.
- **ABI (Aprendizaje Basado en Investigación):** Indagación matemática sobre el comportamiento estocástico de las métricas de rendimiento. Aprenderán que "un solo Accuracy del 90%" es estadísticamente dudoso sin un intervalo de confianza provisto por la validación cruzada.
- **Duración sugerida:** 120 min. (presencial).
- **Modalidad:** Ejecución técnica individual, con integración final en los grupos del Proyecto Integrador.



Tarea 1: La Curva ROC y el Área Bajo la Curva (AUC)

La Exactitud (*Accuracy*) vista en la Semana 15 depende de un umbral estático (ej. 0.5). La Curva ROC evalúa el modelo en **todos los umbrales posibles**, graficando la Tasa de Verdaderos Positivos (TPR o Sensibilidad) contra la Tasa de Falsos Positivos (FPR o $1 - \text{Especificidad}$):

$$TPR = \frac{TP}{TP + FN} \quad ; \quad FPR = \frac{FP}{FP + TN}$$

1.

Abra un nuevo Jupyter Notebook llamado APE_016_ValidacionROC.ipynb.

2. Recuperando el modelo logístico (falla de servidores) de la Semana 15, genere el siguiente código para trazar la curva ROC:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.metrics import roc_curve, auc, classification_report
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split

# 1. Simulación rápida de los datos de la Semana 15
np.random.seed(42)
temp_cpu = np.random.uniform(40, 90, 500).reshape(-1, 1) # X
z = -10 + 0.15 * temp_cpu.ravel()
prob_falla = 1 / (1 + np.exp(-z))
y_real = np.random.binomial(1, p=prob_falla) # Etiquetas (0 o 1)

# División en Entrenamiento y Prueba (70% - 30%)
X_train, X_test, y_train, y_test = train_test_split(temp_cpu, y_real, test_size=0.30,
random_state=42)

# 2. Entrenamiento del Modelo (Usando scikit-learn por compatibilidad con métricas ROC)
modelo = LogisticRegression()
modelo.fit(X_train, y_train)

# Obtener las PROBABILIDADES estimadas para el conjunto de prueba, no solo las clases
(0/1)
# predict_proba devuelve [Prob_Clase_0, Prob_Clase_1]. Tomamos la columna 1.
y_prob_test = modelo.predict_proba(X_test)[:, 1]
```



unl

Universidad
Nacional
de Loja

3. Cálculo de la Curva ROC y AUC

```
fpr, tpr, umbrales = roc_curve(y_test, y_prob_test)
roc_auc = auc(fpr, tpr)
```

4. Visualización

```
plt.figure(figsize=(8, 6))
plt.plot(fpr, tpr, color='darkorange', lw=2, label=f'Curva ROC (AUC = {roc_auc:.3f})')
plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--', label='Clasificador Aleatorio (AUC = 0.5)')
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('Tasa de Falsos Positivos (FPR)')
plt.ylabel('Tasa de Verdaderos Positivos (TPR)')
plt.title('Curva Característica Operativa del Receptor (ROC)')
plt.legend(loc="lower right")
plt.grid(alpha=0.3)
plt.show()
```

Reporte detallado de clasificación con umbral por defecto (0.5)

```
y_pred_test = modelo.predict(X_test)
print("\n--- Reporte de Clasificación (Threshold = 0.5) ---")
print(classification_report(y_test, y_pred_test))
```

Tarea 2: Hito Final del Proyecto - Consolidación del Modelo Regional (ABP)

Esta tarea requiere la integración de su equipo de trabajo.

1. Abran el archivo Jupyter principal de su Proyecto Integrador.
2. Identifiquen el mejor modelo predictivo generado durante el ciclo (Regresión Lineal Múltiple de la Sem 14 o Regresión Logística de la Sem 15).
3. **Si es Clasificación (Logística):** Replique el código de la Tarea 1 para graficar la Curva ROC de su proyecto y reporte el valor AUC.
4. **Si es Regresión (Lineal):** Calcule las métricas RMSE (Root Mean Squared Error) y MAE (Mean Absolute Error) comparando `y_test` con `y_pred_test`.
5. Redacten un párrafo ejecutivo (formato Markdown) que sintetice la utilidad del modelo:
¿Es este modelo lo suficientemente preciso como para ser implementado en una empresa o institución de Loja?



unl

Universidad
Nacional
de Loja

Tarea 3: Preparación de Visualizaciones para la Casa Abierta

Para la presentación de la Semana 17, el código crudo no es suficiente; se requiere comunicación efectiva.

1. Construya al menos **dos gráficos de alto impacto visual** utilizando seaborn que resuman el problema regional y la solución predictiva.
2. Limpie su Notebook: elimine celdas de pruebas fallidas, estructure con títulos #, ##, y asegúrese de que el flujo de lectura (Data Cleaning → EDA → Modeling → Evaluation) sea lógico y profesional.

Tarea 4: ABI - Validación Cruzada Estocástica (K-Fold Cross Validation)

El train_test_split es peligroso: dependiendo de la semilla aleatoria (random_state), el modelo puede parecer excelente o terrible por pura suerte probabilística.

1. Investigue el concepto de K -Fold Cross Validation.
2. Ejecute el siguiente código para dividir su set de entrenamiento simulado en 5 "dobles" (Folds) y calcular el rendimiento promedio.

```
from sklearn.model_selection import cross_val_score
```

```
# Ejecutar validación cruzada con K=5 folds
```

```
k_folds = 5
```

```
# cv requiere el modelo, los predictores (X) y las respuestas (y). Usamos el set completo.
```

```
scores_auc = cross_val_score(modelo, temp_cpu, y_real, cv=k_folds, scoring='roc_auc')
```

```
print(f"--- Análisis de Validación Cruzada (K={k_folds}) ---")
```

```
print(f"AUC de cada Fold: {np.round(scores_auc, 3)}")
```

```
print(f"AUC Promedio Estocástico (E[AUC]): {scores_auc.mean():.3f}")
```

```
print(f"Desviación Estándar ( $\sigma_{AUC}$ ):  $\pm$ {scores_auc.std():.3f}")
```

```
if scores_auc.std() > 0.10:
```

```
    print("Advertencia: El modelo es inestable (alta varianza entre particiones).")
```


```
else:
```

```
    print("Éxito: El modelo es estable y generaliza bien.")
```


3. Aplique cross_val_score a su modelo regional del Proyecto Integrador. Documente si la desviación estándar del rendimiento le da confianza matemática para implementarlo en producción

5. Resultados del Grupo:

Tarea 1




Tarea 2




El modelo de predicción logística es altamente viable para su implementación en casas de valores o instituciones financieras de Loja. Debido a que el valor AUC reportado refleja una buena capacidad de discriminación, la herramienta permite automatizar la detección de operaciones críticas que superan el promedio histórico de liquidez

Su precisión es suficiente para ser utilizada como un sistema de alerta temprana en el análisis de riesgo. No obstante, se recomienda su uso como complemento al juicio experto, dado que eventos atípicos podrían no estar totalmente capturados por el modelo lineal inicial.

Tarea 3



Solución Predictiva: Volumen de Títulos vs Capital Esperado





1. Distribución del Capital Movilizado por Top 20 Emisores Bursátiles

Este gráfico de cajas horizontal nos permite observar la distribución del `Monto_Efectivo` (capital movilizado) para los veinte emisores más activos. Al usar una escala logarítmica, podemos apreciar la gran variabilidad en los montos de transacción y cómo se concentran para cada emisor. Es crucial para entender la asimetría y segmentación del mercado regional, identificando qué emisores manejan las transacciones de mayor valor y cómo se distribuye el capital, necesario para detectar operaciones críticas.

2. Solución Predictiva: Volumen de Títulos vs Capital Esperado

El gráfico conjunto (`JointPlot`) visualiza la relación entre la Cantidad de títulos transaccionados y el `Monto_Efectivo` resultante. La línea de regresión muestra una tendencia positiva, por lo que a mayor cantidad de títulos, mayor es el monto de la transacción. Muestra cómo variables como la Cantidad pueden ser usadas para predecir el `Monto_Efectivo` y, por ende, identificar transacciones de alto valor. Las distribuciones marginales complementan la información sobre la variabilidad de cada una de estas dos variables clave.

Tarea 4

```

---
--- VALIDACIÓN CRUZADA: MODELO BURSÁTIL REGIONAL ---
AUC promedio (5-Folds): 0.9281
Desviación Estándar ( $\sigma$ ):  $\pm 0.0289$ 
Puntajes de cada iteración (AUC por Fold):
[0.9263 0.9127 0.9813 0.9613 0.9392]
DICTAMEN: El modelo presenta una desviación estándar mínima.
CONFIANZA: Alta. Es apto para implementación en producción.

```

Si la desviación estándar es menor a 0.05, se podría decir que el modelo es consistente independientemente de qué subconjunto de transacciones de la BVG se analice. Un buen modelo debe ser robusto ante variaciones naturales de la muestra

Un AUC promedio elevado con baja σ da la certidumbre de que el algoritmo funcionará correctamente con datos futuros de la bolsa. Esto reduce el riesgo de errores a futuro.

Dado que el volumen de datos bursátiles regionales es grande, un resultado de validación cruzada estable confirma que la relación entre Cantidad, Precio y `Monto_Alto` no es producto del azar, permitiendo su implementación segura en sistemas de análisis de riesgo financiero en instituciones de la región.

Enlace al Google Colab:
<https://colab.research.google.com/drive/1lqS8mmw7cxDxdIGw7zvlbzQ0euEUqbtA?usp=sharing>

6. Preguntas de Control:

- ¿Cuál es la naturaleza de un clasificador cuyo AUC es 0,5 y por qué su comportamiento es ontológicamente indistinguible del azar?

Un clasificador con un Área Bajo la Curva (AUC) de 0.5 es un modelo que no tiene capacidad de discriminación. Equivalente a un clasificador que asigna etiquetas de clase de manera aleatoria. Es ontológicamente indistinguible del azar porque no ha aprendido ninguna relación significativa entre las características de entrada (X) y las etiquetas de salida (Y). Si se traza su curva ROC, esta seguiría la línea diagonal que va de (0,0) a (1,1), por lo que la Tasa de Verdaderos Positivos (TPR) es igual a la Tasa de Falsos Positivos (FPR) en todos los umbrales de clasificación. No puede distinguir entre las clases positiva y negativa mejor de lo que lo haría una suposición al azar.

- ¿Es posible afirmar que un modelo es "bueno" basándonos exclusivamente en la exactitud (Accuracy), ignorando la calidad de su juicio sobre las clases minoritarias?



No es posible. La exactitud puede ser engañosa, especialmente en conjuntos de datos desequilibrados (donde una clase es mucho más frecuente que otra). Un modelo podría lograr una exactitud muy alta simplemente prediciendo siempre la clase mayoritaria, sin identificar correctamente un solo caso de la clase minoritaria. Ignora completamente la calidad de su juicio sobre las clases minoritarias, que son importantes. Para evaluar la calidad del juicio sobre clases minoritarias, se necesitan métricas como la Precisión, la Exhaustividad (Recall), el F1-Score o el AUC.

- **Si un modelo fluctúa drásticamente su rendimiento al cambiar los subconjuntos de datos (folds), ¿podemos decir que posee un "conocimiento" robusto o simplemente ha memorizado patrones accidentales?**

Si un modelo fluctúa drásticamente su rendimiento en diferentes subconjuntos de datos, no podemos decir que posee un conocimiento robusto. Podríamos decir que es una clara señal de que el modelo tiene una alta varianza y probablemente ha memorizado patrones accidentales o ruido presente en subconjuntos específicos de los datos de entrenamiento. En lugar de aprender las relaciones subyacentes y que son generalizables, el modelo se ha sobre ajustado a las particularidades de cada fold individual. Un modelo robusto debería mostrar un rendimiento consistente y estable a través de diferentes particiones de los datos.

- **Al someter al modelo a múltiples realidades mediante la Validación Cruzada, ¿cómo nos acercamos más a la esencia de su capacidad predictiva en comparación con una prueba única?**

La Validación Cruzada nos acerca más a la esencia de la capacidad predictiva de un modelo porque simula el rendimiento del modelo en múltiples realidades o situaciones. A diferencia de una prueba única con una sola partición de datos, la validación cruzada:

- **Reduce el sesgo:** Al entrenar y evaluar el modelo en diferentes particiones, se obtiene una estimación más fiable y menos sesgada del error de generalización.
- **Detecta el sobreajuste:** Revela si el modelo se sobre ajusta a un conjunto de datos particular, ya que las grandes variaciones de rendimiento entre los folds indicarían inestabilidad.
- **Utiliza mejor los datos:** Todos los puntos de datos se utilizan tanto para el entrenamiento como para la validación en algún momento.

La validación cruzada da una visión más completa y estadísticamente robusta de cómo se espera que el modelo se comporte con datos nuevos, dándonos una mejor medida de su verdadera capacidad de generalización.

- **¿Por qué el rigor estocástico y el escepticismo matemático constituyen una virtud necesaria para el ingeniero al momento de comunicar la verdad de sus modelos a la sociedad?**

El rigor estocástico y el escepticismo matemático son virtudes esenciales para el ingeniero porque:

Evitar la sobre confianza y la desinformación: Los modelos son representaciones simplificadas de la realidad y siempre tienen limitaciones, sesgos e incertidumbres. Un enfoque riguroso y escéptico evita presentar los modelos como poseedores de la verdad total, lo que podría llevar a decisiones erróneas o a una falsa sensación de seguridad.

Fomentar la transparencia y la confianza: Se comunica de manera honesta sobre las fortalezas y debilidades del modelo, donde se aplica, las suposiciones subyacentes y los posibles escenarios de error.

Gestión del riesgo y la responsabilidad: Un entendimiento de las propiedades estadísticas del modelo permite al ingeniero identificar y cuantificar los riesgos asociados con su despliegue. Crucial en situaciones donde las consecuencias por un errores son graves.

En última instancia, estas virtudes aseguran que la tecnología se utilice de manera responsable y ética. Se fomenta la búsqueda constante de mejoras, la validación exhaustiva y la revisión crítica.

7. Conclusiones.

El uso de modelos avanzados para realizar predicciones requiere de herramientas robustas, como la Validación Cruzada, que permitan verificar la validez del modelo y su capacidad para trabajar con distintos tipos de información, relacionada a su propósito, sin que este presente errores o fallas que puedan poner en peligro su confiabilidad y uso. Una baja desviación estándar en métricas como el AUC a través de los folds no solo valida la consistencia interna del modelo, sino que también ofrece seguridad sobre su capacidad de generalización a datos no vistos.

El rigor estocástico y el escepticismo matemático son virtudes esenciales para el ingeniero. Después de todo, el ingeniero siempre debe conocer los datos con los que trabaja y los resultados obtenidos para poder mejorar el modelo, validarlo o utilizar otro enfoque. Solo así se puede asegurar que las herramientas se utilicen de manera responsable, informada y efectiva, sin poner en peligro la confiabilidad y el propósito para el que fueron creadas.

8. Rúbrica de Evaluación

Esta es la rúbrica simplificada, lista para ser cargada en Moodle:

Criterio	Puntaje	Descripción
Implementación Técnica	3.0 pts	Ejecución correcta del modelo (simulado y regional) y limpieza/documentación del código.
Análisis y Diagnóstico	5.0 pts	Interpretación de coeficientes, diagnóstico efectivo de multicolinealidad (VIF) y visualización.
Reflexión Crítica	2.0 pts	Calidad y profundidad en las respuestas a las preguntas de control (enfoque aristotélico).
Total	10.0 pts	



9. Bibliografía

[1] R. E. Walpole, R. H. Myers, S. L. Myers, y K. Ye, *Probabilidad y estadística para ingeniería y ciencias*, 9na ed. Pearson Educación, 2012.

[2] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 3ra ed. O'Reilly Media, 2022.

[3] SciPy Developers, "scipy.stats Documentation," *SciPy.org*, 2024. [Online]. Disponible: <https://docs.scipy.org/doc/scipy/reference/stats.html>. [Accedido: 18-Mar-2026].

10. Elaboración y Aprobación

- Elaborado por: nombre del Docente responsable de la práctica.
- Aprobado por: nombre del Director de Carrera.

Elaborado por	Cristian R. Narváez Guillén Docente	
Aprobado por	Edison L Coronel Romero Director de Carrera	

11. Anexos

Enlace al Google Colab:
<https://colab.research.google.com/drive/1lqS8mmw7cxDxdIGw7zvlbzQ0euEUqbtA?usp=sharing>